



PROJETO EM CIÊNCIA DE DADOS

SUMÁRIO

SEMESTRE	2025/2
PROJETO	Além do Financeiro: quais são os privilégios da classe política brasileira?
COMPONENTES DO GRUPO	Felipe Augusto Batista Mendes dos Santos Guilherme Couto de Castro Gustavo Henrique da Silva Thiago Farias dos Santos

Breve descrição do problema

Avaliar a quantidade de presenças, participações e faltas justificadas de cada deputado, aplicar diferentes filtros que aproximem o regime de trabalho praticado na Câmara com o regime CLT nestes dados e calcular o ganho efetivo por dia trabalhado de cada deputado, explorando a desigualdade entre tabalhadores e a classe política do Brasil.

Breve descrição da solução proposta

Demonstração gráfica através de Dashboards comparativos, expondo os privilégios assegurados aos deputados federais brasileiros para além dos ganhos financeiros, além de exibir e explorar outliers.

Fases da Metodologia CRISP-DM

Compreensão do negócio:	- Definir objetivo: analisar presenças, participações e faltas dos deputados. - Relacionar dados com parâmetros do regime CLT. - Formular hipóteses: diferença entre ganhos por dia trabalhado de deputados e trabalhadores CLT.	100%
Compreensão dos dados:	- Coletar dados a respeito dos mandatos dos deputados da	100%

	câmara através de fontes oficiais do governo. - Identificar variáveis relevantes: número de sessões realizadas, presenças, ausências (justificadas e não justificadas), participações em votações e remuneração total. - Entender as diferentes justificativas de ausência que um deputado federal pode alegar e se elas se aplicam de alguma forma àquelas aceitas pelo regimento da CLT.	
Modelagem:	- Definir métricas de cálculo (ganho/dia, proporção de presença/ausência). - Aplicar filtros que simulam o regimento da CLT. - Criar cenários comparativos.	100%
Avaliação:	- Verificar se os resultados confirmam as hipóteses. - Analisar se, após aplicação de filtros da CLT, muitos deputados ultrapassariam limites de faltas permitidos. - Comparar os resultados com o objetivo inicial.	100%
Aplicação:	- Apresentar resultados em gráficos e tabelas comparativas. - Discutir o impacto social e político dos achados - Elaborar conclusões sobre a desigualdade trabalhista no país	33%

Resumo do que foi concluído até o momento

O grupo foi capaz de, até então, formular um problema de pesquisa capaz de ser respondido, além de terem sido formuladas hipóteses a partir de breves observações nos dados fornecidos pela Câmara dos Deputados. Também foram calculadas algumas das métricas pretendidas em uma amostra ínfima de dados de deputados selecionados aleatoriamente e, a partir destes cálculos, foi observada a grande possibilidade de que o problema de pesquisa seja respondido.

RELATÓRIO

1. Compreensão do Negócio

A pesquisa almeja avaliar a assiduidade dos deputados federais brasileiros, levando em consideração presenças, participações em votações e faltas (justificadas ou não). Serão determinados filtros baseados nas normas e regimentos da Consolidação das Leis de Trabalho (CLT), considerando apenas os artigos e definições válidos até o presente momento. Os filtros terão como objetivo remover alguns dos privilégios garantidos aos agentes políticos, igualando os deveres trabalhistas de um deputado aos de um trabalhador civil.

Background

Inspirado na constante revolta popular do povo civil brasileiro perante as práticas de inúmeras figuras políticas ao longo da história democrática do país, o tema busca explorar o quão desigual é a realidade dos agentes políticos da federação, não se restringindo somente aos ganhos financeiros que conforme o Decreto Legislativo 172/2022, em vigor desde o dia 1º de fevereiro de 2025, totalizam R\$ 46.366,19 brutos mensais, as métricas principais dirão respeito ao trabalho de cada um dos deputados, avaliando quantos dos que exercem mandatos no presente momento comparecem às sessões legislativas da câmara e quantos destes participam efetivamente de votações realizadas em dias de trabalho, filtrando deputados que vão a sessões, mas não exercem seus deveres como representantes daqueles que os elegem.

Objetivos de negócio e critérios de sucesso

Tem-se como objetivos principais mensurar a assiduidade dos deputados federais atualmente com mandato e avaliar o comprometimento destes com seu papel dentro do regime democrático brasileiro, explorando casos de deputados que possam por quaisquer motivos se abster de uma parte significativa de votações. Para que sejam efetivamente cumpridos tais objetivos, serão mensurados alguns dados, tais quais:

- Percentual de presença de cada deputado;
- Percentual de participações em votações de cada deputado;

- Relação do percentual de presença pelo percentual votações de cada deputado;
- Número de deputados que ultrapassariam os limites de faltas permitidas pelo regime CLT.

Para além das métricas anteriores, também será calculado o salário efetivo de cada deputado após a aplicação de filtros da CLT, considerando como faltas todas aquelas justificadas que excedam o limite de faltas justificadas por ano delimitado pelo que determina a CLT, a partir do número obtido de presenças conforme os parâmetros estabelecidos será calculado o salário com desconto de faltas deste deputado. O mesmo será feito para o número de votações participadas por cada deputado, relacionando salário com número de votações.

Tendo em vista diferenciar deputados com alto impacto externo, para além do impacto político dentro da Câmara dos Deputados, também será calculado o número de dias que um deputado esteve em compromissos relacionados ao mandato (reuniões, comissões, agendas externas, etc.), mas que não impactarão em nenhuma das métricas estabelecidas anteriormente.

Inventário de recursos

Para que seja respondido o problema, serão coletados, filtrados por categorias de interesse e, caso necessário, tratados os dados fornecidos oficialmente pelo Estado brasileiro a respeito das legislaturas de cada um dos deputados. Para maior segurança na obtenção e armazenamento dos dados, serão utilizadas as APIs fornecidas pelo próprio governo.

Requisitos, suposições e restrições

Para a realização do projeto, têm-se os seguintes requisitos: coleta e organização dos dados oficiais de presenças, participações em votações e faltas dos deputados federais; Aplicar filtros e métricas baseadas no regimento da Consolidação das Leis Trabalhistas (CLT) visando simular a frequência requerida de um trabalhador formal; Calcular indicadores de desempenho, como o salário efetivo; Produzir relatórios e demonstrações gráficas que evidenciem a desigualdade entre agentes políticos e agentes civis, assim como demonstrar casos extremos nos dados.

São assumidas as seguintes suposições a respeito da natureza dos dados e para a metodologia utilizada: Os dados fornecidos oficialmente pelo governo são corretos, completos e confiáveis; Somente dias de sessões deliberativas e votações são considerados dias de trabalho, desconsiderando dias em que deputados estão em outras atividades políticas ligadas ao mandato, como agendas externas; Para as justificativas, somente licenças por interesse particular são consideradas faltas; A simulação do regime CLT é válida para comparação, mesmo sabendo que deputados têm funções e jornadas distintas de trabalhadores formais.

Têm-se como restrições do método aplicado: Somente dados públicos oficiais são utilizados, nenhum outro dado para além destes é tomado como parâmetro; Foco em métricas quantitativas (presenças, faltas, salário, participações, etc.), sem análise qualitativa do exercício de cada mandato ou dos projetos votados; Dada a natureza pouco explícita das licenças por interesse particular e à ausência de justificativas formais equivalente às de doença, morte de familiar e licença maternidade da CLT, não é possível avaliar os casos em que deputados se ausentam pelos motivos citados, o mesmo se aplica para afastamentos judiciais não registrados oficialmente.

Terminologia

Para que não existam ambiguidades, nomenclaturas ou conceitos desconhecidos ao leitor, dispõe-se os conceitos necessários abaixo:

- Deputado Federal: Parlamentar eleito para atuar no Congresso Nacional, responsável por criar e votar leis de abrangência nacional.
- Sessão Deliberativa: Reunião oficial da Câmara dos Deputados onde são debatidas e votadas propostas legislativas.
- Presença em Sessão: Registro de que o deputado participou de uma sessão deliberativa.
- Falta Justificada: Ausência em uma sessão ou votação registrada oficialmente, com justificativa aceita (ex.: licença por interesse particular ou missão oficial).
- Missão Oficial: Atividade relacionada ao mandato do deputado, como viagens nacionais ou internacionais, participação em comissões ou eventos representando o país.
- Licença por Interesse Particular: Direito do deputado de se ausentar de sessões e votações por motivos pessoais, sem perda de remuneração.
- Ganho por Dia Trabalhado: Indicador calculado dividindo-se a remuneração total bruta do deputado pelo número de presenças em sessões deliberativas.
- Ganho por Votação Participada: Indicador calculado dividindo-se a remuneração total bruta do deputado pelo número de votações participadas.
- CLT: Consolidação das Leis de Trabalho, conjunto de normas que rege os direitos e deveres de trabalhadores formais no Brasil.

Objetivos de mineração e critérios de sucesso

A mineração de dados para este projeto tem como objetivo extrair, organizar e analisar informações sobre presenças, participações em votações e faltas de deputados federais a partir de dados oficiais disponibilizados pela Câmara dos Deputados. As análises visam:

1. Calcular a presença de cada deputado;
2. Calcular a taxa de votações participadas por cada deputado;
3. Aplicar filtros baseados no regime CLT para simular limites de faltas e jornadas de trabalho;
4. Calcular o ganho efetivo por dia trabalhado e por votação participada por cada deputado;
5. Identificar padrões e evidências de desigualdade entre agentes políticos e agentes civis.

Para que haja sucesso na mineração dos dados, estabelecem-se os critérios:

- Dados corretamente coletados, tratados e organizados de forma consistente;
- Métricas calculadas de maneira precisa e reproduzível;
- Resultados que permitam comparar quantitativamente o desempenho dos deputados com parâmetros da CLT;
- Visualizações e relatórios claros, que evidenciem as conclusões desejadas e permitam confirmar ou refutar as hipóteses iniciais.

Avaliação inicial de técnicas e ferramentas

Serão majoritariamente utilizados recursos computacionais para coleta, filtragem, tratamento e visualizações dos dados necessários para a realização da pesquisa, são eles, de forma geral:

- Linguagem de programação Python para coleta, filtragem e tratamento de dados;
- Application Programming Interface (API) fornecida oficialmente pelo governo;
- Power BI ou ferramenta similar para construção de visualizações gráficas dos dados obtidos.

2. Compreensão dos Dados

Esta seção abrange todas as etapas realizadas desde a coleta inicial até a avaliação da qualidade das informações utilizadas. Tendo como objetivo compreender a estrutura, o conteúdo e as limitações das bases obtidas, assegurando a confiabilidade necessária para as análises subsequentes.

Foram descritos os procedimentos de coleta via API, a estruturação e documentação das variáveis de cada base, as análises exploratórias iniciais para identificação de padrões e inconsistências, e, por fim, as verificações de qualidade que garantiram a integridade e a consistência dos dados consolidados.

Coleta dos dados

O governo brasileiro através do portal Dados Abertos oferece dados referentes aos deputados, senadores, partidos, legislaturas, etc. sendo muitos destes disponibilizados em APIs, que facilitam a coleta de dados automatizada com o uso de softwares, portanto a partir desta ferramenta e da programação de um software, na linguagem Python, foi possível a coleta e armazenamento dos dados de interesse disponíveis no portal. Foram utilizadas requisições HTTP do tipo GET para a coleta de dados, foi necessário o desenvolvimento de um suporte para paginação e de tentativas automáticas de repetição caso houvessem falhas de comunicação entre o portal Dados Abertos e o código.

- Deputados: os dados referentes ao universo de parlamentares foram obtidos através do endpoint /deputados, tendo limite de 100 itens por requisição, dado que este é o conteúdo disponível em cada página da API.
- Eventos: as sessões deliberativas foram extraídas do endpoint /eventos, diferenciando sessões deliberativas ordinárias e extraordinárias por `codTipoEvento = 1` e `codTipoEvento = 2` respectivamente.
- Votações: as votações foram coletadas mês a mês, de 2020 a 2025, salvas em arquivos de extensão csv, identificados por nomes tal qual `votacoes_YYYY-MM.csv`, com o ano e mês respectivos aos dos dados coletados substituindo YYYY e MM respectivamente.
- Votos: os votos por parlamentar foram extraídos do endpoint `/votacoes/{id}/votos`, armazenados em arquivos `votos_YYYY-MM.csv` e então consolidados em `../data/processed/votos_deputados.csv`.
- Presença: as informações anuais de presença foram obtidas através de arquivos CSV públicos, processadas e armazenadas em `../data/processed/presencas.csv`.
- Situação e remuneração: a coleta destas informações foi feita a partir do endpoint `/deputados/{id}`, utilizando referências de códigos disponíveis em `/referencias/deputados/codSituacao`, sendo os dados consolidados em `../data/processed/remuneracoes.csv`.

No decorrer do processo, foi identificado um problema referente a concatenação dos arquivos CSV quando alguns meses não continham dados, resultando em erros do tipo `EmptyDataError`. Para que fosse mitigado, foram realizadas verificações condicionais e gravação idempotente dos arquivos por mês, assegurando a integridade do processamento.

Descrição dos dados

Os dados utilizados foram obtidos e processados a partir de diferentes fontes disponibilizadas pela API da Câmara dos Deputados. Após a coleta, os arquivos foram consolidados no diretório `../data/processed/`, com estrutura e tipagem definidas conforme descrito abaixo.

1. Deputados:

- a. Arquivo: `deputados.json`
- b. Campos:
 - `id (int)`: Identificador único do deputado (chave primária).
 - `nome (str)`: Nome completo do parlamentar.
 - `siglaPartido (str)`: Sigla do partido.
 - `siglaUF (str)`: Unidade federativa de origem.
 - `idLegislatura (int)`: Código da legislatura correspondente.
 - `urlFoto (str)`: Endereço da foto oficial.
 - `email (str)`: Endereço de e-mail institucional.
 - `uriPartido (str)`: Endereço de referência do partido.

2. Sessões e Eventos:

- a. Arquivo: `eventos_sesoes.csv`
- b. Campos:
 - `id_evento (int)`: Identificador do evento (chave primária).
 - `dataHorInicio (datetime)`: Data e hora de início da sessão.
 - `dataHoraFim (datetime)`: Data e hora de encerramento.
- c. Arquivo: `freq_eventos.csv`
- d. Campos:
 - `id_deputado (int)`: Identificador do deputado (chave estrangeira).
 - `num_eventos (int)`: Número total de eventos registrados.

3. Votações:

- a. Arquivo: `votacoes.csv`
 - Consolidação mensal de votações (`votacoes_YYYY-MM.csv`), contendo campos originais da API como `id`, `data`, entre outros.
- b. Arquivo: `votos_deputados.csv`
 - Consolidação dos votos individuais por deputado, incluindo identificação do parlamentar e do voto correspondente.

4. Presenças:

- a. Arquivo: `presencas.csv`
- b. Campos:
 - `id_evento (int)`: Identificador do evento (chave primária).
 - `id_deputado (int)`: Identificador do deputado.
 - `tipo_presenca (str)`: Tipo de presença registrada.
 - `ano_origem (int)`: Ano de referência do registro.

5. Ocupações:

- a. Arquivo: `ocupacoes.csv`
- b. Campos:

- id_deputado (int): Identificador do deputado (chave primária).
 - titulo (str): Título ou cargo exercido.
 - dataInicio/dataFim (str): Período de vigência da ocupação.
6. Remunerações:
- a. Arquivo: remuneracoes.csv
 - b. Campos:
 - id_deputado (int): Identificador do deputado (chave primária).
 - cargo/condicaoEleitoral (str): Cargo e condição eleitoral.
 - situacao (str): Situação do parlamentar.
 - data_inicio (str): Data inicial da remuneração.
7. Situação dos Deputados:
- a. Arquivo: cod_situacao_deputados.json
 - Contém referências de códigos (sigla, nome) utilizados para interpretar o campo “situacao” no arquivo de remunerações

Análise exploratória dos dados

A etapa de análise exploratória teve como objetivo compreender a estrutura e a distribuição dos dados coletados, bem como verificar a consistência entre as bases utilizadas. Foram realizadas operações de inspeção, validação e cruzamento de informações, com o intuito de identificar padrões, anomalias e possíveis inconsistências.

As seguintes explorações foram sugeridas e executadas inicialmente:

- Distribuição de eventos por deputado: análise de variável num_eventos, utilizada como proxy de presença parlamentar, para identificar padrões de participação.
- Evolução temporal das votações: estudo do número de votações por mês (de 2020 até 2025), permitindo observar variações sazonais e tendências de atividade legislativa.
- Mapa anual de presenças: categorização das presenças em tipos (presente, ausente, justificada) com análise comparativa por ano.
- Verificação de consistência entre bases: conferência da correspondência entre identificadores de eventos (id_evento) nos arquivos presencas.csv e eventos_sessoes.csv.

Durante o processo foram observadas a necessidade e as seguintes recomendações da preparação dos dados:

- Filtrar ou ignorar arquivos vazios antes da concatenação.
- Padronizar tipos de dados (por exemplo, conversão de Int64 para identificadores numéricos inteiros).
- Normalizar datas no formato ISO.
- Definir chaves de junção consistentes entre as tabelas (id_deputado, id_evento, id_votacao).

Tais etapas de pré-processamento foram imprescindíveis para garantir a integridade das análises posteriores e a coerência dos resultados obtidos.

Verificação de qualidade dos dados

A verificação de qualidade dos dados teve como objetivo assegurar a consistência, integridade e confiabilidade das bases utilizadas na análise. Para isso, foram aplicados diferentes critérios e abordagens de validação, descritos abaixo.

1. Unicidade dos identificadores:

Foi verificada a ausência de duplicidade nos campos de identificação primária, garantindo que cada registro fosse único.

- deputados.id apresentou unicidade completa
- eventos_sessoes.id_evento também se mostrou único em todo o conjunto de dados.

2. Integridade referencial

Foram realizadas verificações de consistência entre as chaves estrangeiras, assegurando que os relacionamentos entre tabelas estivessem válidos:

- freq_eventos.id_deputado corresponde corretamente aos valores de deputados.id.
- presencas.id_evento apresentou correspondência com eventos_sessoes.id_evento.

3. Coerência de tipos e formatos

Os tipos de dados foram padronizados conforme necessário, com conversão de campos numéricos para o tipo Int64 e tratamento de datas em formato compatível e passível de interpretação (datetime parseável).

4. Tratamento de arquivos vazios

Foram implementadas verificações automáticas para detecção e exclusão de arquivos sem conteúdo antes da etapa de concatenação, evitando erros do tipo EmptyDataError.

5. Eliminação de duplicatas

No conjunto presencas.csv, foram removidas ocorrências duplicadas considerando a combinação dos campos (id_evento, id_deputado, tipo_presenca), garantindo que cada registro representasse uma única instância válida.

6. Resultados obtidos

Após as etapas de verificação e limpeza, o conjunto consolidado de presenças resultou em aproximadamente 564 mil registros válidos. A Coleta mensal de votações apresentou funcionamento estável, embora tenha sido necessária a estrutura de fallback para lidar com meses sem retorno de dados, assegurando a continuidade do processamento.

3. Preparação dos Dados

Nesta etapa estão englobadas todas as atividades necessárias para a transformação dos dados brutos obtidos em um conjunto consistente, integrado e adequado às análises propostas pelo projeto. Com a finalidade de assegurar a qualidade, completude e coerência das informações utilizadas, de forma que possam ser utilizadas em etapas posteriores do projeto, foram realizados procedimentos de limpeza, tratamento de inconsistências, criação de atributos derivados, definição e cálculo de diferentes métricas e cruzamento dos dados utilizados. Ao final consta uma descrição detalhada do estado do dataset resultado do pré-processamento dos dados, assim como o desmembramento de como foram obtidas as métricas utilizadas no estudo.

Limpeza dos dados

Visando a obtenção de um conjunto de dados que satisfaça as necessidades do projeto, foram trabalhadas etapas de filtragem, além de terem sido removidas as entradas duplicadas nos dados, sendo os conjuntos que dizem respeito aos registros de eventos e aos de presenças dos deputados os que necessitaram uma maior atenção. Foram selecionados apenas eventos do tipo Sessão Deliberativa e removidas duplicatas de presenças por deputado e evento.

Por fim, foi investigada a presença de valores faltantes com o auxílio de visualização em *Heatmap* nos *Dataframes* resultantes para identificação de problemas de integridade.

Criação de atributos e registros

Com o objetivo de enriquecer o conjunto de dados utilizado, permitindo análises de maior abrangência acerca do comportamento dos parlamentares, foram criados novos atributos e estruturas derivadas dos dados originais.

Para cada deputado e sessão deliberativa foi gerado um atributo binário que indica a presença de determinado deputado em cada sessão deliberativa, representado por uma flag (0/1). A partir do indicador foram calculadas a contagem total de presenças por deputado e a taxa de presença destes, obtida através da razão do número de presenças registradas pelo total de sessões deliberativas que ocorreram no período analisado. Além destes, um rótulo descritivo para cada deputado foi elaborado, combinando nome, partido e unidade federativa, facilitando a identificação dos parlamentares e possibilitando análises por estado ou partido.

Integração de dados

A integração dos dados foi realizada a partir de múltiplas fontes, incluindo informações dos deputados (JSON), registros de eventos (CSV) e dados de presenças (CSV). O processo ocorreu por meio de operações *merge*, utilizando como chaves primárias os identificadores “id_deputado” e “id_evento”, garantindo o alinhamento semântico entre diferentes tabelas.

Atributos provenientes das fontes originais, tais quais nome, partido e unidade federativa, foram incorporados juntamente com as métricas derivadas de presença calculadas nas etapas anteriores. O tratamento de redundância foi realizado através da remoção de duplicatas e seleção criteriosa das colunas necessárias.

Descrição do dataset final

O dataset resultante, que passou pela aplicação das etapas limpeza, criação de atributos e integração dos diferentes arquivos CSV armazenados no diretório “graph”, consolidou as informações necessárias para a elaboração das demonstrações gráficas através de *dashboards*. O conjunto inclui atributos de identificação dos parlamentares (nome, partido, unidade federativa e um número identificador de cada deputado) em conjunto com as variáveis derivadas referentes ao comportamento legislativo.

Os indicadores calculados foram:

- Quantidade de presenças em sessões deliberativas: valor absoluto obtido a partir da contagem de presenças de cada deputado em sessões deliberativas;
- Taxa de presença: razão entre a quantidade de presenças de um deputado e o total de sessões deliberativas do período analisado;
- Participação em votações: valor absoluto obtido a partir da contagem de votações ocorridas que um deputado não se absteve;
- Taxa de participação: razão entre o número de participação em votações de um deputado e o total de votações que ocorreram no período analisado;
- Quantidade de faltas injustificadas: valor absoluto obtido a partir da contagem de sessões que um deputado não esteve presente e não justificou a falta;
- Ganho por dia trabalhado: razão entre o salário e a quantidade de presenças em sessões deliberativas de um deputado;
- Ganho por votação participada: razão entre o salário e a participação em votações de um deputado;

O conjunto de dados final reflete o resultado das etapas de pré-processamento dos dados, incluindo a remoção de duplicatas, filtragem que mantenha apenas as sessões de relevância e o tratamento de ausências, assim como da geração de atributos derivados e do cruzamento dos dados de presenças, eventos, votações e informações cadastrais de cada deputado. Dados todos critérios de pré-processamento, tem-se um dataset final consistente com padronização das métricas calculadas e que está pronto para análises quantitativas e comparativas entre parlamentares, além de comparações com parâmetros do regime CLT, desta forma permitindo a modelagem e visualização gráfica dos padrões de atuação parlamentar.

4. Autocrítica

Nesta etapa, que configura a finalização do projeto extensionista, uma série de atividades foram necessárias para a concretização de um conjunto de dados capaz de atingir os objetivos da pesquisa. De forma geral, foi realizada a limpeza dos dados obtidos, a fim de evitar distorções nas exibições gráficas e análises posteriores causadas por entradas duplicadas ou incompletas, com valores nulos, além da definição de métricas relevantes e do cruzamento de diversas tabelas de dados em uma única que satisfaça o problema de pesquisa. O maior desafio da etapa de preparação dos dados esteve centrado na junção dos bancos de dados, além da escolha de métricas relevantes para a pesquisa, permitindo a elaboração de gráficos importantes para a compreensão do cenário político brasileiro.